

DETERMINACIÓN DE ÓRBITAS MEDIANTE REDES NEURONALES BASADAS EN LA FÍSICA

Andrea Scorsoglio,* Roberto Furfaro[†]

En este artículo se presenta un nuevo método para resolver problemas de determinación de órbitas denominado «mínimos cuadrados informados por la física» (PILS, por sus siglas en inglés). Utilizamos un tipo concreto de redes neuronales feed-forward de una sola capa denominadas «máquinas de aprendizaje extremo» para conseguir una mayor precisión y flexibilidad que los mínimos cuadrados clásicos. La estimación de mínimos cuadrados se utiliza como referencia para la función de pérdida, a la que se añade un término regularizador basado en las ecuaciones diferenciales que modelan la dinámica del problema. Esto garantiza que la relación aprendida entre la entrada y la salida sea compatible con la física del problema. Los resultados son comparables o mejores que la solución de mínimos cuadrados por lotes, con la ventaja de que no requieren una estimación inicial y permiten resolver la trayectoria completa sin necesidad de integración.

INTRODUCCIÓN

El problema de la determinación de la órbita (OD) siempre ha sido de vital importancia desde los albores de los vuelos espaciales. El éxito de prácticamente cualquier misión está relacionado con la posibilidad de estimar el estado de la nave espacial en un momento dado. Por ejemplo, es importante estimar el estado de una nave espacial tan pronto como sale del lanzador para evaluar los pasos a seguir durante la fase de puesta en servicio. La disponibilidad de algoritmos de OD fiables y precisos también es fundamental para planificar maniobras de corrección y tareas de mantenimiento de la estación, así como para misiones que implican movimiento relativo, como el encuentro y el acoplamiento. Históricamente, la tarea de determinación de la órbita y estimación del estado se ha resuelto mediante la estimación de mínimos cuadrados y los filtros de Kalman y sus respectivas derivaciones.

En la solución de mínimos cuadrados comunes, se utiliza un conjunto de mediciones heterogéneas para estimar un conjunto de pesos constantes que, multiplicados por un conjunto predefinido de funciones básicas, proporcionan una estimación lineal de la medida.^{1,2} Esto se ha ampliado para permitir relaciones no lineales entre parámetros y medidas: el algoritmo resultante se denomina normalmente mínimos cuadrados no lineales o mínimos cuadrados secuenciales. En este caso, el problema no se puede resolver con una simple inversión de matriz, sino que se debe implementar un procedimiento iterativo, ya que las ecuaciones no son explícitas en los parámetros. El filtro de Kalman KF³ y sus variantes⁴ son, en cambio, una clase de métodos recursivos de estimación de estado que se aplican a sistemas lineales. La principal diferencia con respecto a los mínimos cuadrados es que se puede aplicar en tiempo real, lo que aumenta su utilidad en un escenario real. Por lo general, funcionan estimando la función de densidad de probabilidad (pdf) de la distribución de estados. En el caso de los sistemas lineales, se trata de una distribución gaussiana, que está totalmente determinada por su vector medio y su matriz de covarianza. La media y la covarianza se actualizan analíticamente dentro del algoritmo KF. En la práctica, el algoritmo

*Estudiante de doctorado, Departamento de Ingeniería Industrial y de Sistemas, Universidad de Arizona, 1127 E. James E. Rogers Way, Tucson, AZ 85721

[†] Profesor, Departamento de Ingeniería Industrial y de Sistemas, Universidad de Arizona, 1127 E. James E. Rogers Way, Tucson, AZ 85721

Se utiliza a menudo para sistemas no lineales mediante la linealización de los modelos de proceso y medición del sistema. Las diferentes formas de linealizar los modelos dan lugar a diferentes filtros, a saber, el filtro de Kalman extendido (EKF), el EKF iterado (IEKF)⁵ y el filtro de Kalman de regresión lineal (LRKF).⁶

El objetivo de este trabajo es utilizar redes neuronales para resolver el problema de la OD. Existen ejemplos de aprendizaje automático y redes neuronales aplicados a problemas de OD, pero se trata de un campo relativamente nuevo. Furfaro et al.⁷ demostraron que es posible crear un mapeo inverso preciso entre las mediciones de ángulos y los parámetros orbitales utilizando máquinas de aprendizaje extremo. Sharma⁸ presentó un algoritmo para la determinación de órbitas y la cancelación de interferencias del magnetómetro para cubsats, demostrando su robustez en una variedad de escenarios (por ejemplo, solo Doppler, basado en la posición, órbita lunar y órbita terrestre baja). Lee et al.⁹ presentaron una nueva e interesante forma de simular observaciones de velocidad de alcance y alcance inclinado utilizando el aprendizaje automático. Peng et al.¹⁰ también demostraron la viabilidad del aprendizaje automático, concretamente de las redes neuronales artificiales (ANN), para mejorar la precisión de la predicción de órbitas.

El objetivo de este trabajo es aprovechar los fundamentos del aprendizaje automático aplicado al problema OD utilizando las máquinas de aprendizaje extremo basadas en la física (PIELM) recientemente desarrolladas para regularizar el algoritmo de aprendizaje y mejorar la solidez dinámica de la solución estimada. Las PIELM estándar son redes neuronales específicas, desarrolladas para resolver problemas directos e inversos regidos por ecuaciones diferenciales paramétricas (ED). El entrenamiento de estas redes, como en cualquier método basado en la física, está regulado por la física del problema. En particular, la solución latente de la DE paramétrica se aproxima mediante redes neuronales (NN); la DE que modela la física del problema se incrusta entonces, en su forma implícita, en la función de pérdida de la NN. Así, la DE impulsa el entrenamiento de la red actuando como regulador que penaliza el entrenamiento de la red cuando se viola la física del problema. Por lo general, estas NN se entrenan mediante métodos basados en gradientes. En caso de que el método emplee máquinas de aprendizaje extremo (ELM), como en este caso, el entrenamiento puede llevarse a cabo en un solo paso utilizando mínimos cuadrados de norma mínima. Con este trabajo aprovechamos la potencia y la facilidad de implementación de las redes neuronales para resolver un conjunto de problemas OD basados en mínimos cuadrados. Esto da lugar a un algoritmo capaz de ofrecer un rendimiento similar al de los mínimos cuadrados por lotes, con algunas ventajas. En concreto, el algoritmo es capaz de estimar la evolución completa del estado sin ningún paso de integración y sin necesidad de proporcionar una estimación inicial, produciendo al mismo tiempo resultados más precisos.

El resto del artículo está organizado de la siguiente manera: la sección II introduce los conceptos de determinación de órbitas y redes neuronales basadas en la física como elementos fundamentales de nuestro método; la sección III describe en detalle los mínimos cuadrados basados en la física (PILS); la sección IV muestra los resultados numéricos del método y los compara con los mínimos cuadrados clásicos; y, por último, la sección V contiene la conclusión.

CONCEPTOS TEÓRICOS

En esta sección se presentan los componentes básicos de las técnicas de determinación de órbitas basadas en la física: el problema clásico de la determinación de órbitas y las redes neuronales basadas en la física en forma de PIELM.

El problema de la determinación de órbitas

El problema de la determinación de órbitas se plantea normalmente como un problema de estimación en el que se utiliza un conjunto de mediciones de la misma o una serie de cantidades relacionadas con el problema para estimar la

estado del sistema. Las principales técnicas en este campo son la estimación por mínimos cuadrados (y mínimos cuadrados por lotes) y los filtros de Kalman. En este caso, nos centramos en el primer grupo como concepto básico para crear nuestro marco OD. Según los mínimos cuadrados, supongamos que hay un conjunto, o lote, de valores medidos y_j , tomados en instantes de tiempo discretos t_j :

$$\{y_1, t_1; y_2, t_2; \dots; y_m, t_m\} \quad (1)$$

y un modelo matemático que correlaciona la medición con algunas constantes x_i :

$$y(t) = \sum_{i=1}^n x_i h_i(t) \quad (2)$$

donde $h_i(t)$ son un conjunto de funciones básicas. Las x_i son un conjunto de constantes cuyos valores numéricos se desconocen. En los mínimos cuadrados clásicos, buscamos un conjunto de estimaciones, denotadas por $\{x_1, x_2, \dots, x_n\}$, que pueden utilizarse para predecir $y(t)$. Sin embargo, pueden surgir errores de medición entre el valor «verdadero» $y(t)$

y el valor previsto (estimado) $\hat{y}(t)$. Consideramos que el error de medición es un proceso aleatorio desconocido. Suponemos que la medición y_j y la salida estimada $\hat{y}_j$ se modelan mediante las ecuaciones:

$$y_j = \sum_{i=1}^n x_i h_i(t_j) + v_j \quad (3)$$

$$\hat{y}_j = \sum_{i=1}^n \hat{x}_i h_i(t_j) \quad (4)$$

donde v_j es el error de medición. Entonces podemos definir la siguiente identidad:

$$y_j = \sum_{i=1}^n \hat{x}_i h_i(t_j) + e_j \quad (5)$$

donde e_j es el error residual entre la medición real y la medición prevista, definido como:

$$e_j = y_j - \hat{y}_j \quad (6)$$

El principio de mínimos cuadrados de Gauss selecciona, como opción óptima para los parámetros desconocidos, el $\hat{x}$ particular que minimiza la suma de los cuadrados de los errores residuales, dada por

$$J = \frac{1}{2} e^T e \quad (7)$$

En el caso de los mínimos cuadrados clásicos, esto se expresa utilizando las definiciones anteriores:

$$J = \frac{1}{2} (\tilde{y} - N \hat{x})^T (\tilde{y} - N \hat{x}) = \frac{1}{2} \tilde{y}^T \tilde{y} - \tilde{y}^T N \hat{x} + \hat{x}^T N^T N \hat{x} \quad (8)$$

A continuación, podemos tomar el gradiente de J para obtener la condición necesaria de optimalidad:

$$\nabla_{\hat{x}} J = N^T \tilde{y} - N^T N \hat{x} = 0 \quad (9)$$

Lo cual se puede resolver para $\hat{x}$:

$$\hat{x} = (N^T N)^{-1} N^T \tilde{y} \quad (10)$$

En este caso, utilizamos los mínimos cuadrados ponderados, que se basan en el método que acabamos de describir. Se obtienen considerando la siguiente función objetivo: ¹

$$J = \frac{1}{2} \mathbf{e}^T \mathbf{W} \mathbf{e} \quad (11)$$

donde $\mathbf{W}$ es una matriz de ponderación diagonal. La solución se deriva entonces de la misma manera que antes:

$$\nabla_{\hat{\mathbf{x}}} J = \mathbf{N}^T \mathbf{W} \mathbf{N} \hat{\mathbf{x}} - \mathbf{N}^T \mathbf{W} \mathbf{y}^{\sim} = 0 \quad (12)$$

y resolviendo para

$$\hat{\mathbf{x}} = (\mathbf{N}^T \mathbf{W} \mathbf{N})^{-1} \mathbf{N}^T \mathbf{W} \mathbf{y}^{\sim} \quad (13)$$

En teoría, la matriz de pesos puede ser cualquier matriz diagonal, pero se sabe que, al elegirla como la inversa de la matriz de covarianza del error de observación $\mathbf{R}^{-1}$, la solución de mínimos cuadrados proporciona el estimador de varianza mínima.

Problema OD de alcance y velocidad de alcance Aquí desarrollamos la solución clásica de mínimos cuadrados para la estimación del estado inicial dada una serie de observaciones de alcance y velocidad de alcance desde tres estaciones terrestres independientes. El problema es el problema de dos cuerpos sin perturbaciones, cuyas ecuaciones de movimiento son:

$$\dot{\mathbf{r}} = \mathbf{v} \quad (14)$$

$$\dot{\mathbf{v}} = -\frac{\mu}{r^3} \mathbf{r} \quad (15)$$

En este caso, $\mathbf{x} = [\mathbf{r}, \mathbf{v}]$. Consideramos que las estaciones terrestres se encuentran en las posiciones $\mathbf{r}_{s1}$, $\mathbf{r}_{s2}$, $\mathbf{r}_{s3}$ en el marco ECEF* y las consideramos conocidas. La naturaleza no lineal del problema requiere el uso de una estimación no lineal por mínimos cuadrados.² En este caso, las mediciones reales y estimadas se expresan como:

$$\mathbf{y}^{\sim} = \mathbf{f}(\mathbf{x}) + \mathbf{v} \quad (16)$$

$$\mathbf{y}^{\wedge} = \mathbf{f}(\hat{\mathbf{x}}) \quad (17)$$

donde $\mathbf{f}(\cdot)$ es una función no lineal del estado real o estimado. El error es:

$$\mathbf{e} = \mathbf{y}^{\sim} - \mathbf{y}^{\wedge} \quad (18)$$

La función objetivo es entonces:

$$J = \frac{1}{2} \mathbf{e}^T \mathbf{W} \mathbf{e} \quad (19)$$

Esto se optimiza linealizando el modelo en torno a una trayectoria de referencia y resolviendo las variaciones en contraposición al estado real. Esto funciona inicializando el vector $\mathbf{x}_0$ con una estimación inicial. Dada esta estimación inicial, se genera la trayectoria de referencia integrando las ecuaciones de movimiento

e integrando simultáneamente el STM utilizando $\dot{\Phi} = \mathbf{A}(t)\Phi$, siendo $\mathbf{A}(t)$ la matriz del sistema linealizado y las condiciones iniciales $\Phi(0, 0) = \mathbf{I}$. El estado estimado se puede expresar como:

$$\hat{\mathbf{x}} = \mathbf{x}_c + \delta \mathbf{x} \quad (20)$$

El modelo de observación

es:

$$\mathbf{f}(\hat{\mathbf{x}}) \approx \mathbf{f}(\mathbf{x}_c) + \mathbf{N} \delta \mathbf{x} \quad (21)$$

* Centrado en la Tierra, fijo en la Tierra

Donde $\mathbf{N} = \frac{\partial f}{\partial \mathbf{x}} \big|_{\mathbf{x}_c}$ es el jacobiano calculado sobre la trayectoria de referencia. La variación de las observaciones es:

$$\delta \mathbf{y} = \mathbf{y}^* - f(\mathbf{x}^*) \approx \mathbf{y}^* - f(\mathbf{x}_c) - \mathbf{N} \delta \mathbf{x} = \delta \mathbf{y}_c - \mathbf{N} \delta \mathbf{x} \quad (22)$$

donde $f(\mathbf{x}_c)$ son las observaciones calculadas en la trayectoria de referencia. El objetivo es entonces:

$$J = \frac{1}{2} \delta \mathbf{y}^T \mathbf{W} \delta \mathbf{y} = (\delta \mathbf{y}_c - \mathbf{N} \delta \mathbf{x})^T \mathbf{W} (\delta \mathbf{y}_c - \mathbf{N} \delta \mathbf{x}) \quad (23)$$

Que se puede optimizar de la misma manera que 8. Por lo tanto, la solución para la variación del estado inicial es:

$$\delta \mathbf{x}^* = (\mathbf{N}^T \mathbf{W} \mathbf{N})^{-1} \mathbf{N}^T \delta \mathbf{y} \quad (24)$$

A continuación, se actualiza la estimación del estado inicial:

$$\mathbf{x}_0^{k+1} = \mathbf{x}_0^k + \delta \mathbf{x}^* \quad (25)$$

y se calcula una nueva trayectoria de referencia. Esto se repite hasta que se cumple el criterio de convergencia $\|\mathbf{x}_0^{k+1} - \mathbf{x}_0^k\| \leq \epsilon$.

Máquinas de aprendizaje extremo basadas en la física (PIELM)

Para definir correctamente PIELM¹¹ es importante introducir las redes neuronales basadas en la física (PINN), ya que PIELM es un subconjunto particular de estas y comparte la idea básica. Las PINN fueron introducidas por primera vez por Raissi et al.¹² como un método para aproximar soluciones a ecuaciones diferenciales parciales no lineales generales, así como a algunos problemas inversos. A diferencia de los elementos finitos y el método basado en mallas en general, las PINN utilizan una red neuronal profunda (DNN) como función base para aproximar la solución. La ecuación diferencial parcial y sus condiciones de contorno se muestrean en ubicaciones dentro y en los límites del dominio, respectivamente. La salida de la DNN en esas ubicaciones se utiliza para calcular los residuos de la EDP en los puntos internos y en los límites. A continuación, la pérdida se expresa como la suma de los errores en las condiciones de contorno conocidas y los residuos basados en las relaciones físicas del problema. A continuación, se aprenden los pesos y sesgos de la red neuronal minimizando la pérdida mediante un método de optimización basado en gradientes. Cabe señalar que, aunque se introdujeron para resolver EDP, también pueden emplearse para resolver EDE y sistemas de EDE en los que la única entrada a la red es el tiempo y no se definen las condiciones de contorno. Se ha demostrado que esto funciona bien en una variedad de modelos de tiempo continuo y discreto.¹² En términos matemáticos, los fundamentos de la PINN pueden describirse considerando un problema general en la forma:

$$u_t + \mathbf{N}[u] = 0, \quad \mathbf{x} \in \Omega, \quad t \in [0, T] \quad (26)$$

donde u es la solución latente y $\mathbf{N}[\cdot]$ es cualquier operador diferencial no lineal. A continuación, definimos $f(t, \mathbf{x})$ como el lado izquierdo de la ecuación 26:

$$f(t, \mathbf{x}) = u_t + \mathbf{N}[u] \quad (27)$$

La idea principal de PINN es aproximar la solución $u(t, \mathbf{x})$ con una red neuronal. La red neuronal se convierte entonces en una red neuronal con información física al entrenar sus pesos y sesgos minimizando la pérdida del error cuadrático medio:

$$MSE = MSE_u + MSE_f \quad (28)$$

donde

$$MSE_u = \frac{1}{N_u} \sum_{i=1}^{N_u} |u(t^i, x^i) - u^i|^2 \quad (29)$$

y

$$MSE_f = \frac{1}{N_f} \sum_{i=1}^{N_f} |f(t^i, x^i)|^2 \quad (30)$$

$\{t^i, x^i, u^i\}_{i=1}^{N_u}$ denotan los datos de entrenamiento iniciales y de contorno en $u(t, x)$ y $\{t^i, x^i\}_{i=1}^{N_f}$ denotan los puntos de colocación dentro del dominio para $f(t, x)$. Esta pérdida garantiza que la solución respete tanto la dinámica como las condiciones iniciales/limitrofes.

PIELM es un método híbrido basado en redes neuronales que integra los conceptos de PINN explicados anteriormente y la potencia de las máquinas de aprendizaje extremo (ELM).¹³ Las ELM son un tipo particular de redes de alimentación directa de una sola capa en las que los pesos y sesgos de entrada se eligen aleatoriamente y se mantienen constantes a lo largo del proceso de aprendizaje, mientras que los pesos de salida son los únicos parámetros entrenados. Esto permite que el entrenamiento se lleve a cabo en un solo paso, lo que reduce drásticamente el tiempo de cálculo. Las ELM también han demostrado tener una capacidad de representación excepcional y una mejor generalización que los procedimientos clásicos de aprendizaje basados en gradientes.¹⁴ En términos matemáticos, considerando una red de propagación hacia adelante de una sola capa con n neuronas, x es el estado de entrada y y es la salida, una ELM es una correspondencia entre la entrada y la salida a través de una serie de funciones básicas no lineales llamadas funciones de activación σ y un conjunto de parámetros llamados pesos de entrada (v), sesgos (b) y pesos de salida (β). La salida de una sola neurona es $\sigma(v^T x + b_j)$. Para un conjunto de datos dado $\{x_k, y_k\}_{k=1}^N$ con N muestras, la salida es

$$y = N(x)\beta \quad (31)$$

donde

$$N = [h(x_1), h(x_2), \dots, h(x_T)]^T \quad (32)$$

es la salida de la capa oculta, con

$$h(x_k) = [\sigma(v_1^T x_k + b_1), \sigma(v_2^T x_k + b_2), \dots, \sigma(v_n^T x_k + b_n)] \quad (33)$$

El entrenamiento se logra minimizando el error entre la salida prevista y la salida real $T s = y - T$:

$$J = \frac{1}{2N} s^T s \quad (34)$$

La solución se obtiene analíticamente como:

$$\beta = N^\sim T \quad (35)$$

donde $N^\sim$ es la pseudoinversa de la matriz N , que en general no es cuadrada. La figura 1 muestra una representación de un ELM. Por lo tanto, PIELM se reduce a elegir un ELM como representación paramétrica del estado de la EDP/ECD y aprender sus parámetros optimizando una función de pérdida basada en la física es decir, la suma del coste de mínimos cuadrados de la EDP y las ECB, como se ha explicado anteriormente.




Figura 1. Arquitectura ELM

MÍNIMOS CUADRADOS INFORMADOS POR LA FÍSICA (PILS)

La forma en que utilizamos PIELM para resolver el problema OD se basa en aproximar el estado $\mathbf{x}$ del sistema con un ELM como función de la época t . En este caso, queremos estimar el estado completo del sistema $\mathbf{x} = [\mathbf{r}, \mathbf{v}]$, que comprende la posición y la velocidad. Debido a la simplicidad de una red de una sola capa, podemos lograrlo creando una red cuya salida sea la posición 3D $\mathbf{r}$ y obteniendo la velocidad mediante la diferenciación analítica de la salida. Dicho esto, la posición del satélite se expresa como:

$$\mathbf{r} = \text{ELM}(t) \quad (36)$$

Inicializamos los pesos de entrada $\mathbf{w}$ y los sesgos $\mathbf{b}$ como vectores aleatorios entre -1 y 1 de longitud n , donde n es el número de neuronas. Los pesos de salida ξ también se inicializan como un vector aleatorio de longitud $3n$ entre 0 y 1.

La matriz $\mathbf{F} = \mathbf{N}$ se obtiene, junto con sus derivadas, utilizando una función de activación tangente hiperbólica

$$\mathbf{F} = \mathbf{N} \quad (37)$$

$$\dot{\mathbf{F}} = \frac{d\mathbf{N}}{dt} \quad (38)$$

$$\ddot{\mathbf{F}} = \frac{d^2\mathbf{N}}{dt^2} \quad (39)$$

$$(40)$$

El cambio de nombre se introduce aquí para diferenciarlos de la formalización ELM. La salida de la red (es decir, la posición del satélite) y sus derivadas son entonces:

$$\mathbf{r} = [r_1, r_2, r_3] = [\mathbf{F}^T \xi_1, \mathbf{F}^T \xi_2, \mathbf{F}^T \xi_3] \quad (41)$$

$$\dot{\mathbf{r}} = [\dot{r}_1, \dot{r}_2, \dot{r}_3] = [\dot{\mathbf{F}}^T \xi_1, \dot{\mathbf{F}}^T \xi_2, \dot{\mathbf{F}}^T \xi_3] \quad (42)$$

$$\ddot{\mathbf{r}} = [\ddot{r}_1, \ddot{r}_2, \ddot{r}_3] = [\ddot{\mathbf{F}}^T \xi_1, \ddot{\mathbf{F}}^T \xi_2, \ddot{\mathbf{F}}^T \xi_3] \quad (43)$$

$$(44)$$

Donde $\xi = [\xi_1, \xi_2, \xi_3]$ se ha dividido en tres partes asociadas a los tres componentes de la posición. A continuación, utilizamos esta correspondencia para aproximar la medición utilizando el mismo modelo de medición derivado para la estimación clásica por mínimos cuadrados descrita anteriormente. Concretamente, utilizamos el alcance ρ y la velocidad de alcance $\dot{\rho}$ de tres estaciones terrestres distintas. Al utilizar la correspondencia, estos componentes adoptan la forma

$$\begin{aligned} \rho_{NN_i} &= \sqrt{(r_1 - x_{s_i} \cos \vartheta + y_{s_i} \sin \vartheta)^2 + (r_2 - x_{s_i} \sin \vartheta - y_{s_i} \cos \vartheta)^2 + (r_3 - z_{s_i})^2} \\ \dot{\rho}_{NN_i} &= [(r_1 - x_{s_i} \cos \vartheta + y_{s_i} \sin \vartheta)(\dot{r}_1 + x_{s_i} \sin \theta \dot{\theta} + y_{s_i} \cos \theta \dot{\theta}) + \\ &\quad (r_2 - x_{s_i} \sin \vartheta - y_{s_i} \cos \vartheta)(\dot{r}_2 - x_{s_i} \cos \theta \dot{\theta} + y_{s_i} \sin \theta \dot{\theta}) + \\ &\quad (r_3 - z_{s_i})\dot{r}_3] / \rho_{NN_i} \end{aligned} \quad (45)$$

donde i se refiere a la estación terrestre i -ésima y el subíndice NN sirve para diferenciarla de las observaciones reales ρ_i y $\dot{\rho}_i$. ϑ y θ son la rotación angular y la velocidad de rotación del marco ECEF con respecto al marco inercial centrado en la Tierra (ECI). El residuo es entonces:

$$R = [R_{f1}, R_{f2}, R_{f3}, R_{\rho1}, R_{\rho2}, R_{\rho3}, R_{\dot{\rho}1}, R_{\dot{\rho}2}, R_{\dot{\rho}3}] \quad (46)$$

donde

$$R_{f_i} = \ddot{r}_i + \frac{\mu}{r_i^3} r_i \quad (47)$$

$$R_{\rho_i} = \rho_i - \rho_{NN_i} \quad (48)$$

$$R_{\dot{\rho}_i} = \dot{\rho}_i - \dot{\rho}_{NN_i} \quad (49)$$

$$(50)$$

Estos residuos deben minimizarse para resolver el problema OD. El paralelismo con PINN es evidente, ya que los términos R_{ρ_i} y $R_{\dot{\rho}_i}$ garantizan que la solución se acerque a las observaciones (que actúan como restricción en este caso), y el término R_{f_i} garantiza que la solución respete la física del problema. A continuación, los residuos se diferencian analíticamente con respecto a los parámetros para aprender ξ . Las derivadas resultantes se organizan en una matriz que representa la jacobiana del método:

$$J = \frac{dR}{d\xi} \quad (51)$$

Al ser el problema no lineal, no podemos resolver directamente para ξ . En su lugar, la solución se refina mediante un proceso iterativo. La solución para la variación de los pesos $\delta\xi$ se obtiene resolviendo el problema de mínimos cuadrados de norma mínima:

$$\min_{\delta\xi} \|J\delta\xi - R\| \quad (52)$$

que también minimiza $\|\delta\xi\|$. A continuación, se actualiza el vector de peso:

$$\xi^{k+1} = \xi^k + \delta\xi \quad (53)$$

hasta que se cumpla el criterio de convergencia $\|R\| < \epsilon$.

Tabla 1. Órbitas de prueba

	a (km)	e (grados)	i (grados)	ω (grados)	Ω (grados)	ϑ_0 (grados)
LEO	9000	0,1	60	0	45	0
GEO	42164	0	0	0	0	100
Molniya	26600	0,74	63,4	270	0	190

Tabla 2. Estaciones terrestres Coordenadas ECEF

	x (km)	y (km)	z (km)
Estación Pacífico	-5127,51	-3794,16	0
Pirinclik	3860,90	3238,50	3898,10
Thule	549,50	-1380,87	6182,20

RESULTADOS NUMÉRICOS

El método propuesto se prueba y se compara con la solución clásica de mínimos cuadrados. Se prueba en tres escenarios de determinación de órbita. En primer lugar, consideramos una órbita terrestre baja (LEO), con un muestreo de 300 mediciones durante un periodo de 500 segundos. A continuación, consideramos una órbita geoestacionaria (GEO), con un muestreo de 300 mediciones durante un periodo de 10 000 segundos. Por último, consideramos una órbita Molniya, con un muestreo de 300 muestras durante 5000 segundos. Los parámetros orbitales de todas las órbitas se indican en la tabla 1. Las mediciones consisten en valores de alcance y velocidad de alcance de tres estaciones terrestres cuyas coordenadas en el marco ECEF se indican en la tabla 2. Cabe señalar que las estaciones terrestres que figuran en la tabla se han elegido únicamente con fines de prueba y no guardan relación con los requisitos de ninguna misión específica. El método es independiente de la selección de las estaciones terrestres. Las observaciones se crean añadiendo un ruido gaussiano al alcance real y a la velocidad de alcance. Las desviaciones estándar de los errores en el alcance y la velocidad de alcance son 1 m y 0,1 m/s, respectivamente. El número de neuronas n es 10 en todos los casos.

Las tablas 3, 4 y 5 muestran el estado inicial real, el estado inicial estimado y el error, tanto con mínimos cuadrados clásicos (LS) como con PILS. Los resultados muestran un rendimiento muy similar al de los mínimos cuadrados clásicos y, en muchos casos, se mejora la precisión de la estimación del estado inicial. Las figuras 2, 3 y 4 muestran las órbitas y la parte de la trayectoria considerada para el proceso de estimación, junto con los estados reales y estimados y el error entre ellos. Es interesante observar que, dado que PILS estima todos los estados a la vez, los errores no muestran tendencias particulares al alza, lo que podría ocurrir al estimar los estados propagando el estado inicial estimado. La tabla 6 muestra el RMSE entre los estados de todo el arco estimados utilizando PILS y los estados integrados a partir del estado inicial estimado utilizando LS. Esto muestra que PILS supera al LS clásico en la mayoría de los casos, y solo le cuesta superar al LS en algunos de los componentes de velocidad. Cabe señalar que los parámetros del PILS (es decir, el número de neuronas) no se han optimizado, por lo que podría haber margen de mejora.

CONCLUSIÓN

El método propuesto combina el poder del aprendizaje automático y las técnicas de determinación de órbitas por mínimos cuadrados para crear un nuevo método de determinación de órbitas denominado «mínimos cuadrados informados por la física» (PILS). Se basa en el PIELM, en el que se utiliza un ELM para aproximar la solución latente de una ecuación diferencial ordinaria (ODE) o una ecuación diferencial parcial (PDE). Esto funciona penalizando la función de pérdida del método de optimización utilizado para obtener el

Tabla 3. LEO: estimación del estado inicial (todas las cantidades en km y km/s)

	real	estimado LS	estimado PILS	error LS	error PILS
x	5727,5649	5727,5669	5727,5663	$2,07 \times 10^{-3}$	$1,38 \times 10^{-3}$
y	5727,5649	5727,5626	5727,5635	$-2,25 \times 10^{-3}$	$-1,40 \times 10^{-3}$
z	0	0,0016	-0,0006	$1,69 \times 10^{-3}$	$-6,18 \times 10^{-4}$
$\dot{x}$	-2,6012	-2,6012	-2,6011	$1,25 \times 10^{-5}$	$-8,02 \times 10^{-6}$
$\dot{y}$	2,6012	2,6012	2,6011	$7,29 \times 10^{-6}$	$8,87 \times 10^{-6}$
$\dot{z}$	6,3716	6,3716	6,3715	$3,41 \times 10^{-6}$	$1,25 \times 10^{-6}$

Tabla 4. GEO: estimación del estado inicial (todas las cantidades en km y km/s)


	real	estimado LS	estimado PILS	error LS	error PILS
x	-7321,7017	-7321,6989	-0,7321,7033	$2,77 \times 10^{-3}$	$-1,61 \times 10^{-3}$
y	41523,4341	41523,4349	41523,4341	$8,28 \times 10^{-4}$	$6,59 \times 10^{-5}$
z	0	$3,9437 \times 10^{-4}$	$1,7603 \times 10^{-4}$	$3,94 \times 10^{-4}$	$1,76 \times 10^{-3}$
$\dot{x}$	-3,0279	-3,0279	-3,0279	$-2,52 \times 10^{-8}$	$9,07 \times 10^{-8}$
$\dot{y}$	-0,5339	-0,5339	-0,5339	$2,17 \times 10^{-7}$	$-3,64 \times 10^{-8}$
$\dot{z}$	0	$2,56 \times 10^{-9}$	$-4,3728 \times 10^{-7}$	$2,56 \times 10^{-9}$	$-4,37 \times 10^{-7}$

Tabla 5. Molniya: estimación del estado inicial (todas las cantidades en km y km/s)


	real	estimado LS	estimado PILS	error LS	error PILS
x	-7704,0147	-7703,9989	-7704,0144	$1,57 \times 10^{-2}$	$3,23 \times 10^{-4}$
y	19563,3282	19563,3127	19563,3287	$-1,55 \times 10^{-2}$	$5,12 \times 10^{-4}$
z	39067,0638	39067,0739	39067,0637	$1,01 \times 10^{-2}$	$-9,14 \times 10^{-5}$
$\dot{x}$	-1,4089	-1,4089	-1,4089	$1,90 \times 10^{-7}$	$-1,56 \times 10^{-7}$
$\dot{y}$	-0,4474	-0,4474	-0,4474	$2,01 \times 10^{-6}$	$1,01 \times 10^{-6}$
$\dot{z}$	-0,8936	-0,8936	-0,8936	$5,29 \times 10^{-7}$	$7,44 \times 10^{-9}$

Tabla 6. RMSE para todos los casos (todas las cantidades en km y km/s)


	LEO LS	LEO PILS	GEO LS	GEO PILS	Molniya LS	Molniya PILS
x	$5,52 \times 10^{-3}$	$5,92 \times 10^{-4}$	$2,40 \times 10^{-3}$	$7,75 \times 10^{-4}$	$1,58 \times 10^{-2}$	$4,05 \times 10^{-4}$
y	$1,26 \times 10^{-3}$	$5,59 \times 10^{-4}$	$1,97 \times 10^{-3}$	$3,31 \times 10^{-4}$	$1,06 \times 10^{-2}$	$1,05 \times 10^{-3}$
z	$2,54 \times 10^{-3}$	$3,60 \times 10^{-4}$	$3,73 \times 10^{-4}$	$1,49 \times 10^{-3}$	$1,13 \times 10^{-2}$	$5,81 \times 10^{-4}$
$\dot{x}$	$1,25 \times 10^{-5}$	$3,27 \times 10^{-6}$	$1,14 \times 10^{-7}$	$4,29 \times 10^{-7}$	$1,37 \times 10^{-7}$	$4,23 \times 10^{-7}$
$\dot{y}$	$8,47 \times 10^{-6}$	$3,54 \times 10^{-6}$	$2,02 \times 10^{-7}$	$1,13 \times 10^{-7}$	$2,17 \times 10^{-6}$	$1,31 \times 10^{-6}$
$\dot{z}$	$3,24 \times 10^{-6}$	$1,35 \times 10^{-6}$	$9,67 \times 10^{-9}$	$4,64 \times 10^{-7}$	$4,14 \times 10^{-7}$	$6,06 \times 10^{-7}$



(a) Trayectoria




(b) Posición




(c) Velocidad


Figura 2. Resultados LEO



(a) Trayectoria




(b) Posición




(c) Velocidad


Figura 3. Resultados GEO



(a) Trayectoria



(b) Posición



(c) Velocidad

Figura 4. Resultados de Molniya

parámetros de la red con el sistema dinámico. En este caso, la pérdida se compone del error entre el rango calculado y la medición de la velocidad de rango, dada la salida de posición de la red y sus derivadas, y las observaciones ruidosas procedentes de tres estaciones terrestres. Esta pérdida se aumenta entonces con el residuo dinámico basado en las ecuaciones de movimiento, de ahí la definición basada en la física. El método funciona excepcionalmente bien en tres escenarios de prueba diferentes: una órbita LEO, una órbita GEO y una órbita Molniya. En particular, el rendimiento es comparable o superior al de los mínimos cuadrados clásicos por lotes cuando se estima el estado inicial del arco. Además, dado que PILS estima todo el arco, a diferencia de LS, el RMSE que utiliza PILS en todo el arco es menor para casi todos los estados en todos los casos, en comparación con el arco integrado que comienza desde el estado inicial estimado utilizando LS. Además, la estructura particular de PILS le permite proporcionar una estimación precisa sin necesidad de una suposición del estado inicial, lo que podría ser complicado de obtener en un escenario real. En general, con este artículo demostramos que las redes neuronales son una herramienta poderosa que puede emplearse para la determinación de órbitas, que logra un rendimiento similar o superior al de las técnicas de mínimos cuadrados existentes, incluso sin ajuste de parámetros. Se podrían obtener posibles mejoras optimizando los parámetros de la red en función de la tarea en cuestión.

REFERENCIAS

- [1] J. L. Crassidis y J. L. Junkins, *Estimación óptima de sistemas dinámicos*. CRC Press, 2011.
- [2] B. Schutz, B. Tapley y G. H. Born, *Determinación estadística de órbitas*. Elsevier, 2004.
- [3] R. G. Brown y P. Y. Hwang, *Introducción a las señales aleatorias y al filtrado Kalman aplicado: con ejercicios MATLAB*, vol. 4. John Wiley & Sons Nueva York, NY, EE. UU., 2012.
- [4] T. Lefebvre*, H. Bruyninckx y J. De Schutter, «Filtros de Kalman para sistemas no lineales: una comparación de rendimiento», *Revista internacional de control*, vol. 77, n.º 7, 2004, pp. 639-653.
- [5] L. Fan y Y. Wehbe, «Extended Kalman filtering based real-time dynamic state and parameter estimation using PMU data» (Estimación dinámica en tiempo real del estado y los parámetros basada en el filtro de Kalman ampliado utilizando datos PMU), *Electric Power Systems Research*, vol. 103, 2013, pp. 168-177.
- [6] T. Lefebvre, H. Bruyninckx y J. De Schutter, «A The Linear Regression Kalman Filter», *Nonlinear Kalman Filtering for Force-Controlled Robot Tasks*, pp. 205-210, Springer, 2005.
- [7] R. Furfaro, R. Linares, M. K. Jah y D. Gaylor, «Mapping sensors measurements to the resident space objects behavior energy and state parameters space via extreme learning machines», *Congreso Internacional de Astronáutica*, 2016.
- [8] S. Sharma, *Aplicaciones del aprendizaje automático en la estimación del estado y el entorno de las naves espaciales*. Tesis doctoral, 2018.
- [9] B.-s. Lee, W.-G. Kim, J. Lee y Y. Hwang, «Machine Learning Approach to Initial Orbit Determination of Unknown LEO Satellites» (Enfoque de aprendizaje automático para la determinación de la órbita inicial de satélites LEO desconocidos), *Conferencia SpaceOps 2018*, 2018, p. 2566.
- [10] H. Peng y X. Bai, «Enfoque de aprendizaje automático basado en redes neuronales artificiales para mejorar la precisión de la predicción de la pre ción orbital», *Journal of Spacecraft and Rockets*, vol. 55, n.º 5, 2018, pp. 1248-1260.
- [11] V. Dwivedi y B. Srinivasan, «Physics Informed Extreme Learning Machine (PIELM): un método rápido para la solución numérica de ecuaciones diferenciales parciales», *Neurocomputing*, vol. 391, 2020, pp. 96- 118.
- [12] M. Raissi, P. Perdikaris y G. E. Karniadakis, «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations» (*Redes neuronales basadas en la física: un marco de aprendizaje profundo para resolver problemas directos e inversos que implican ecuaciones diferenciales parciales no lineales*), *Journal of Computational Physics*, vol. 378, 2019, pp. 686-707.
- [13] G.-B. Huang, Q.-Y. Zhu y C.-K. Siew, «Máquina de aprendizaje extremo: teoría y aplicaciones», *Neuro-computing*, vol. 70, n.º 1-3, 2006, pp. 489-501.
- [14] G.-B. Huang, L. Chen, C. K. Siew, *et al.*, «Aproximación universal mediante redes constructivas incrementales de alimentación directa con nodos ocultos aleatorios», *IEEE Trans. Neural Networks*, vol. 17, n.º 4, 2006, pp. 879-892.